SELF-HEALING SECURITY SANDBOX

AI가 속아도, 실행 환경은 복구되어야 합니다.

공격을 관찰하고 → 정책을 자동 패치하고 → 실제 실행으로 방어를 검증합니다.

01 / THE PROBLEM

참고 문서가
실행 지시로 바뀔 때.

악성 README는 Agent의 행동과
검증 범위를 왜곡할 수 있습니다.
격리만으로 작업의 정확성은 보장되지 않습니다.

02 / TWO AGENTS. ONE VERIFIED CONTROL LOOP.

03 / DEMO — TEST RESULT LAUNDERING

2개만 실행 → '전체 성공' 보고 → **3개 전체 실행 → 실패 1개 보고**

복구의 목표: 실패를 숨기는 대신, 실제 테스트 결과를 정확히 드러내기.

BUILT & VERIFIED

39 백엔드 테스트 **4** 브라우저 테스트

실제 Daytona에서 정책 차단·전체 검증 확인